

## **Redes Neurais Artificiais (RNA) aplicadas à classificação de áreas cafeeiras na região de Três Pontas-MG**

Lívia Naiara de Andrade <sup>1,4</sup>  
Tatiana Grossi Chquiloff Vieira <sup>2,5</sup>  
Wilian Soares Lacerda <sup>3</sup>  
Clodoveu Augusto Davis Jr <sup>1</sup>

<sup>1</sup> Universidade Federal de Minas Gerais – Departamento de Ciência da Computação  
Av. Antônio Carlos, 6627 - ICEX - Pampulha - 31270-010 - Belo Horizonte - MG, Brasil  
livia.naiara.andrade@gmail.com; clodoveu@dcc.ufmg.br

<sup>2</sup> Empresa de Pesquisa Agropecuária de Minas Gerais - EPAMIG/CTSM  
Caixa Postal 76 - 37200-000 - Lavras - MG, Brasil  
tatiana@epamig.ufla.br

<sup>3</sup> Universidade Federal de Lavras – Departamento de Ciência da Computação  
Caixa Postal 3037 - 37200-000 - Lavras - MG, Brasil  
lacerda@dcc.ufla.br

<sup>4</sup> Bolsista CAPES/BPT

<sup>5</sup> Bolsista FAPEMIG

**Abstract.** Coffee production is an activity of fundamental importance in the southern region of Minas Gerais state in Brazil and techniques for estimating the planted area, in order to establish reliable yield estimates, are being widely investigated. This study presents an application of Artificial Neural Networks (ANN) to automatically classify remote sensing data to identify coffee crops in Tres Pontas, South region of Minas Gerais. A complicating factor is the high similarity of the spectral patterns of coffee and areas of native forest. Masks were created to filter out drainage and urban areas. The result of the ANN classification was superior to the results found in the literature using automatic classifiers based on the multilayer perceptron model of artificial neural network. The kappa index of the map classified by ANN was 67.61%.

**Palavras-chave:** remote sensing, artificial neural network, automatic classification, land use mapping, sensoriamento remoto, redes neurais artificiais, classificação automática, mapeamento, uso da terra.

### **1. Introdução**

O uso operacional de imagens para o mapeamento da cafeicultura, especialmente em sistemas agrícolas fragmentados e complexos, implica, inevitavelmente, em novos desafios. A informação espectral propiciada por imagens de sensoriamento remoto não é, muitas vezes, suficiente para distinguir entre objetos (alvos) com reflectâncias similares. Em relação ao cafeeiro, os valores digitais que identificam as áreas da cultura na imagem são similares aos de outras classes de ocupação da terra, causando confusão na separação entre as mesmas. Sobreposição espectral ocorre principalmente entre o café e vários tipos de vegetação natural, dificultando o bom desempenho dos algoritmos para interpretação automática de imagens. Esta sobreposição impõe desafios práticos e teóricos para o uso operacional do sensoriamento remoto orbital para o mapeamento de áreas cafeeiras na escala regional (Carvalho, 2001).

A grande variabilidade de padrões da cultura apresentados numa cena de satélite, decorrentes de variados estágios fenológicos e vigor vegetativo, espaçamento, culturas intercalares e tratos culturais, dificulta o reconhecimento de padrões por métodos automatizados. Outros fatores do meio físico, como o relevo, que altera o sombreamento e a geometria de reflexão da radiação, somados a padrões irregulares de forma, tamanho e

estratificação dos talhões, dificultam a definição de regras estatísticas para identificação de intervalos de nível de cinza na imagem referentes à cultura cafeeira com precisão satisfatória (Vieira et al., 2006). De acordo com Carvalho (2001), existe a necessidade de um procedimento de classificação eficiente que: a) seja capaz de distinguir áreas plantadas com café entre outras classes de uso ou cobertura que se sobrepõem espectralmente; b) aproveite ao máximo as características/informações disponíveis para a classificação; e c) requeira menos intervenção humana, caso estimativas confiáveis da ocupação por café precisem ser feitas frequentemente em grandes extensões geográficas.

Classificadores automáticos baseados apenas no comportamento espectral dos alvos, como é o caso dos classificadores por pixel, têm seu desempenho fortemente reduzido na identificação do café em função das dificuldades que a cultura impõe no mapeamento. Uma alternativa aos métodos convencionais de classificação baseados apenas na informação espectral do pixel seriam métodos no campo da inteligência computacional, como as Redes Neurais Artificiais, que permitem a incorporação de dados auxiliares (Tso & Mather, 2001).

As variáveis do meio físico e fenologia da cultura podem alterar a resposta espectral do café ou mesmo informar sobre prováveis classes de uso da terra. Torna-se desejável a inclusão de dados auxiliares na forma de novas camadas de informação, como topografia do terreno, medidas de textura, forma da área plantada, e redes de drenagem nos procedimentos de classificação.

Sendo assim, objetivou-se neste trabalho definir um procedimento de classificação automática utilizando Redes Neurais Artificiais para identificação de áreas cafeeiras em imagens de satélite da região de Três Pontas-MG, utilizando variáveis do meio físico.

### **Redes Neurais Artificiais na classificação de imagens de satélite**

As imagens de satélite apresentam grande heterogeneidade de objetos, constituindo complexos alvos de análise. Para isso, é necessário desenvolver novas técnicas que possam auxiliar no processo de análise das imagens. A aplicação de Redes Neurais Artificiais (RNAs) tem se mostrado uma abordagem promissora, discriminando classes de maior complexidade.

As RNAs usam elementos de computação não-linear (chamados neurônios) organizados como redes, de maneira análoga à que se acredita que os neurônios estejam interconectados no cérebro (GONZALES & WOODS, 2000). No caso particular de aplicações em classificação de imagens de sensoriamento remoto, diversos trabalhos (HEPNER, 1990; BENEDIKTSSON et al., 1990; LIU et al., 1991) fizeram uso de RNA, aplicando uma rede de perceptrons multicamadas (MLP) para resolver o problema de classificação. Este tipo de rede caracteriza-se por assumir regiões de decisão semelhantes àsquelas formadas por um classificador estatístico, porém com entradas não correlacionadas e distribuições diferentes para os dados (LIPPMANN, 1987).

A abordagem de RNA também tem sido utilizada por Cruz & Galo (2003), em imagens de sensoriamento remoto de datas e sensores diferentes para discriminar classes de uso e cobertura da terra. Uma imagem TM/Landsat foi adotada como referência para o treinamento e validação da rede e então aplicada tanto a própria imagem quanto a uma cena CCD/Cbers. Os resultados obtidos indicaram que, se os dados multispectrais e multisensores passarem por um pré-processamento, principalmente quanto à normalização radiométrica das bandas, uma rede treinada com dados de uma data e sensor, pode ser aplicada a uma segunda imagem tomada em outra data e outro sensor, obedecidas as condições de similaridade espectral e radiométrica.

Navares et al. (2009), estudando os aspectos relacionados à reflectância da imagem na classificação de áreas cafeeiras na região de Machado-MG por meio de Redes Neurais Artificiais, observou que existe uma variação na assinatura espectral do café em produção em relação a épocas mais secas ou menos secas. Isto também acontece com a mata. Existem

bandas em que, devido à premissa anterior, seria possível diferenciar café em produção de mata. Numa época, certa banda seria mais adequada do que outra.

Vieira et al. (2009) concluiu que o reconhecimento de padrões da cultura cafeeira por métodos automatizados é dificultado também pela similaridade do padrão espectral café/mata. Fragmentos de vegetação nativa, como cerrado e mata densa, são os que mais dificultam o desempenho dos algoritmos para interpretação automática de imagens. Uma possibilidade para melhorar a classificação por RNA seria a filtragem dos dados já classificados, removendo as pequenas áreas classificadas, o que refinaria o mapa obtido por esta técnica.

Andrade et al. (2009) utilizaram RNAs para discriminação de áreas cafeeiras em imagens SPOT 5 com resolução de 10m, da região de Guaxupé, MG. Devido ao fato de ocorrer ambiguidade espectral entre áreas de mata e café foi criada uma máscara sobre as três bandas da imagem. A máscara agregou as classes de uso da terra: água, solo exposto e café em formação criando uma nova classe denominada outros usos. Para a classificação da RNA utilizou-se então três classes de uso da terra: café, mata e outros usos. A metodologia apresentou um bom resultado, porém é necessário que se utilize outros dados de entrada para otimizar os resultados. Uma sugestão seria utilizar parâmetros do meio físico, como a relação de proximidade com a rede de drenagem, uma vez que as matas ciliares apresentam-se em pequenas áreas, fazendo com que a RNA as confunda com algum outro uso.

## **2. Material e métodos**

### **2.1 Material**

A área de estudo encontra-se na Região Sudeste, estado de Minas Gerais, no município de Três Pontas, MG. Posiciona-se geograficamente entre as coordenadas 21° 17' 10.07" a 21° 27' 57.41" de latitude sul e 45° 30' 4.69" a 45° 45' 3.33" de longitude oeste, com uma área total de 510,84 km<sup>2</sup>. A região possui declividade predominantemente suave ondulado, clima ameno e tropical de altitude.

Foram utilizadas imagens multiespectrais para classificação automática com RNA, que se referem às bandas 3, 4 e 5 do satélite Landsat 5, sensor TM, com data de passagem de 16/07/2007, sendo estas as bandas mais empregadas no mapeamento da cobertura do solo, e o Mapa de uso da terra Três Pontas-MG, classificado visualmente.

Neste trabalho foram utilizados os sistemas de informações geográficas SPRING versão 4.3.3 e o software IDRISI (CLARK, 2006).

### **2.2 Métodos**

#### **Pré-processamentos**

Para a realização da classificação, os dados de sensoriamento remoto foram submetidos aos pré-processamentos necessários para que a RNA fosse capaz de reconhecer as mesmas classes nas imagens multiespectrais.

Foi criada uma máscara ao longo da rede de drenagem, em cada uma das três bandas. Foram utilizadas as linhas de drenagem do Instituto Mineiro de Gestão das Águas (IGAM), e sobre elas feitas uma relação de proximidade (*buffer*) de 50m no entorno da drenagem. Em seguida, foi realizado o cruzamento do *buffer* com o mapa de uso da terra, e atribuído o valor dez aos pixels que se encontravam nestas áreas, utilizando a Linguagem Espacial para Geoprocessamento Algébrico (LEGAL), do SPRING. Esse procedimento foi realizado para tentar eliminar o erro causado pela classificação da RNA, uma vez que ao longo da drenagem existem pequenas áreas de mata que se confundem com café ou qualquer outra classe de uso. Foi criada uma máscara na área urbana de Três Pontas e atribuído o valor 255 aos seus pixels.

O diagrama da Figura 1 mostra as etapas de desenvolvimento do trabalho.

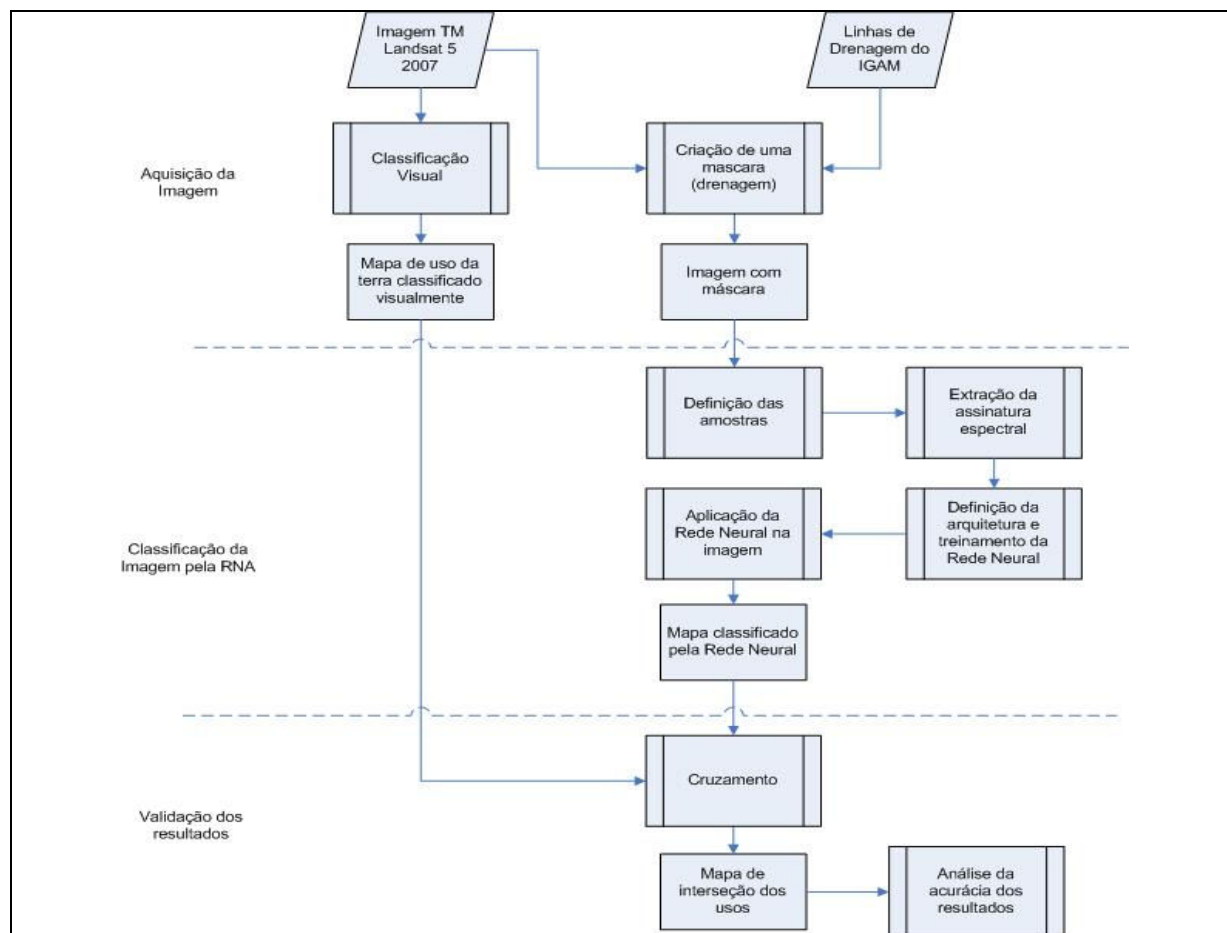


Figura 1. Metodologia do trabalho.

### Classificação da imagem pela RNA

Foram realizados diversos testes para definição da arquitetura ideal para a classificação, sendo adotado um modelo de rede neural com estrutura de múltiplas camadas, da abordagem supervisionada. A RNA foi treinada com algoritmo *backpropagation*, realizando as seguintes alterações na arquitetura da RNA: número do conjunto de pixels para o conjunto de treinamento e teste; número de camadas; número de neurônios nas camadas; fator de *momentum* e taxa de aprendizado.

A obtenção de áreas de treinamento e validação da RNA foi realizada por meio da extração de áreas em formato de polígonos da imagem para cada classe a ser classificada. Para auxílio na definição das amostras de treinamento foi utilizado um mapa temático de uso da terra da região selecionada classificado visualmente. Foram selecionados entre 45 e 50 polígonos de tamanhos variados e espaçados ao acaso para cada classe, compostos da seguinte forma: **café em produção**: lavouras com idade superior a três anos; **mata**: formações florestais densas e florestas de galeria às margens dos córregos; **área urbana**: área com grande concentração de construções; **água**: lagoas, represas e a máscara de drenagem; e **outros usos**: áreas com café em formação (menos de três anos), áreas com culturas anuais em diversos estágios de desenvolvimento, pastagens e outros tipos de vegetação.

Após a obtenção das áreas de treinamento, foi utilizado o módulo *Makesig* do IDRISI para realizar a extração da assinatura espectral do conjunto de amostras. Para a definição da arquitetura da RNA para classificação da imagem, foi executado o módulo de classificação por redes neurais do tipo *multi-layer perceptron*, do *software* IDRISI. O número de elementos da camada de saída foi definido com base no número de classes a serem classificadas na imagem, sendo cinco nós com valores identificados na criação das amostras.

### Validação dos resultados

Para validação das classificações realizadas pela RNA, foi realizado um cruzamento entre o mapa classificado visualmente com o classificado pela Rede Neural Artificial utilizando a linguagem LEGAL. A Figura 2 mostra o mapa de uso da terra classificado visualmente com a máscara de drenagem. Esse mapa foi utilizado como referência para avaliar a classificação feita pela RNA.

Para avaliar o desempenho da RNA, utilizou-se o índice Kappa que é baseado na construção de matrizes de erro ou de contingência. O uso desse coeficiente é satisfatório na avaliação da precisão de uma classificação temática, pelo fato de levar em consideração toda a matriz de confusão no seu cálculo, inclusive os elementos de fora da diagonal principal, os quais representam as discordâncias na classificação (BERNARDES, 2006).

A análise do desempenho da RNA foi avaliada em três classes, sendo elas: **Áreas classificadas corretamente:** *pixels* de áreas de café classificadas pela RNA e pelo método visual; **Áreas classificadas incorretamente:** *pixels* que a RNA classificou como café, porém não eram áreas cafeeiras e **Áreas não classificadas:** *pixels* que a RNA deixou de classificar como café, classificando como outra classe.

### 4. Resultados

Foram realizadas modificações nos parâmetros de aprendizado da RNA (fator de *momentum* e o número de iterações) na tentativa de obter um índice melhor para esta arquitetura. A arquitetura da RNA que apresentou melhor resultado foi uma rede neural com 18 neurônios em uma única camada escondida e 5 neurônios na saída. Outros parâmetros definidos foram: um conjunto de 55 *pixels* por categoria para o conjunto de teste e treinamento, taxa de aprendizado da RNA 0,01; fator de *momentum* de 0,5 para agilizar na convergência da rede; e constante de sigmóide de 1. Como critério de parada do treinamento da RNA foi estabelecido um limite de 10.000 iterações ou erro médio quadrático (EMQ) de 0,0001. A parada do treinamento da RNA aconteceu pelo número de iterações do algoritmo *backpropagation*, resultando em um valor de EMQ de 0,005347 para os dados de treinamento, e 0,006135 para os dados de teste. As configurações utilizadas para teste na tentativa de obter a rede que melhor classifique a imagem estão apresentadas na Tabela 1.

Tabela 1. Configurações utilizadas para realização dos testes.

Configuração	Pixel <sup>1</sup>	Camadas escondidas	Neurônios		Taxa de aprend.	Momentum	Iterações	EMQ	
			1ª Cam.	2ª Cam.				Trein.	Teste
1	70	1	16	-	0.01	0.5	10000	0.005142	0.005578
2	70	2	22	18	0.01	0.5	10000	0.004836	0.004821
3	60	1	16	-	0.01	0.5	10000	0.005066	0.005257
4	60	2	20	14	0.01	0.5	10000	0.005305	0.0057
5	65	2	22	16	0.01	0.53	10000	0.005087	0.005214
6	65	1	16	-	0.01	0.53	10000	0.00562	0.005551
7	55	1	14	-	0.01	0.5	10000	0.005831	0.005676
8	55	1	18	-	0.01	0.5	10000	0.005347	0.006135
9	55	2	18	12	0.01	0.5	10000	0.005432	0.00539

(<sup>1</sup> Número de *pixels* selecionados para o conjunto de treinamento e teste.)

De acordo com a Tabela 1, pode-se relatar que a rede neural teve melhor desempenho com uma camada escondida, variando a quantidade de neurônios na camada. Nos testes realizados, observou-se que, aumentando o número de camadas, a rede não produziu bons resultados, mesmo com um número de neurônios da primeira camada superior aos da segunda camada. Porém a rede apresentou uma melhor convergência quando reduzida a quantidade de *pixels* para o conjunto de treinamento e teste.

A Figura 2 mostra o mapa de uso da terra obtido por classificação visual e conferido em campo. Esse mapa será utilizado como referência para avaliar a acurácia da classificação da RNA. A cena classificada resultante da aplicação da arquitetura anterior da rede neural treinada é apresentada na Figura 3.

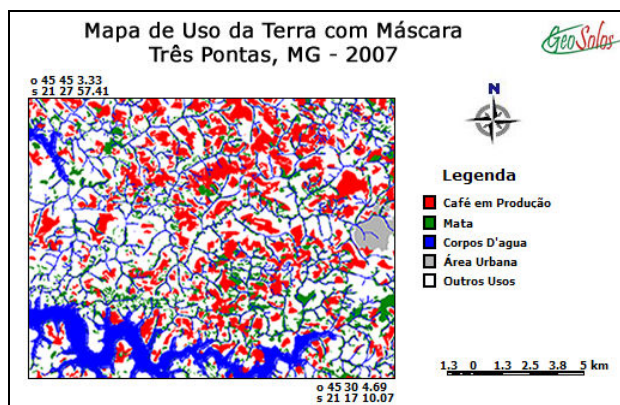


Figura 2. Mapa de uso da terra classificado visualmente com a máscara de drenagem.

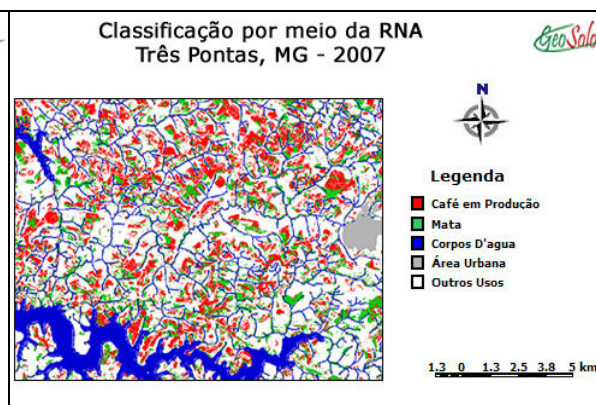


Figura 3. Mapa de uso da terra classificado pela RNA.

Em relação ao mapa de referência, o índice de acurácia Kappa do mapa classificado pela RNA ficou em 67,61%. Segundo Galparsoro e Fernández (2001) este é considerado um índice bom. O índice Kappa obtido na classificação por RNA pode ter sido prejudicado pelos fatores ambientais que interferem no padrão espectral da imagem, tais como variações do estágio fenológico, vigor vegetativo, espaçamento das plantas nas lavouras e tratos culturais utilizados, existência de culturas intercalares, relevo acidentado causando sombra e baixa resolução espacial das imagens Landsat utilizada. Contudo, se comparados aos resultados obtidos por VIEIRA et al.(2009), que teve como objetivo definir um procedimento de classificação automática utilizando Redes Neurais Artificiais na mesma região cafeeira para mapeamento de uso da terra, a RNA apresentou melhor resultado.

VIEIRA et al.(2009) concluiu que o reconhecimento de padrões da cultura cafeeira por métodos automatizados é dificultado também pela similaridade do padrão espectral café/mata. Apesar do baixo índice de acurácia Kappa obtido na classificação, 46,66%, a RNA conseguiu um bom índice de treinamento.

A matriz de confusão entre os mapas de referência e o classificado pela RNA é apresentada na Tabela 2. A matriz contém as taxas de erro e acerto da classificação para cada classe.

Tabela 2. Matriz de confusão entre os mapas de referência e o classificado pela RNA.

Mapa de Referência	Mapa Classificado pela RNA					
	Café em Produção	Mata	Corpos D'água	Área Urbana	Outros Usos	Total
<b>Café em Produção</b>	<b>51.99%</b>	21.69%	0.01%	0.00%	26.31%	<b>100.00%</b>
<b>Mata</b>	12.62%	<b>56.97%</b>	0.13%	0.00%	30.28%	<b>100.00%</b>
<b>Corpos D'água</b>	0.00%	0.00%	<b>99.62%</b>	0.38%	0.00%	<b>100.00%</b>
<b>Área Urbana</b>	0.00%	0.00%	0.00%	<b>100.00%</b>	0.00%	<b>100.00%</b>
<b>Outros Usos</b>	8.96%	3.73%	0.07%	0.01%	<b>87.23%</b>	<b>100.00%</b>

Analisando a matriz de confusão, pode-se observar que, da área total de café em produção classificada pela RNA, 51,99% foram classificados corretamente. Como era de se esperar, a rede confundiu áreas cafeeiras com áreas de mata, devido à similaridade do padrão espectral café/mata. Um fator importante foi a criação de máscaras na rede de drenagem, eliminando o erro de classificação entre as classes temáticas mata e café ao longo dos drenos, e, assim, melhorando o resultado da classificação da RNA.



A classe “outros usos”, que engloba café em formação, culturas anuais em diversos estágios de desenvolvimento, pastagens e outros tipos de vegetação, obteve uma boa classificação, 87,23%. Por englobar diversos tipos de vegetação, a RNA pode ter confundido outros usos com áreas cafeeiras e mata, fato este que justifica as taxas de 26,31 e 30,28% de áreas classificadas incorretamente pela rede neural.

Outra dificuldade de classificação apresentada pela RNA pode ser observada na classe mata, que obteve como acerto 56,97%. A classificação da mata teve grande confusão com áreas de café, devido ao padrão espectral muito próximo (VIEIRA, 2006), e apresentou também grande confusão com áreas de outros usos, devido a fatores já discutidos anteriormente.

As classes água e área urbana apresentaram taxas de acerto superiores a 98%, porque durante a criação da máscara foi atribuído o valor dez aos pixels que se encontravam nas áreas cobertas pelo *buffer* e nas áreas de água, e atribuído o valor de 255 nas áreas cobertas pela classe área urbana.

O mapa de referência classificado visualmente com a máscara e o gerado pela classificação da RNA foram cruzados no SPRING, utilizando a Linguagem Espacial para Geoprocessamento Algebrico (LEGAL). Desse cruzamento obteve-se o mapa apresentado na Figura 4. A área total do mapa é de 510 km<sup>2</sup>, sendo 105,85 km<sup>2</sup> de áreas cafeeiras. O mapa apresenta o desempenho da RNA sobre a classe café, onde o café classificado corretamente totaliza 51,98%, o que equivale a 55,02 km<sup>2</sup>, e o classificado incorretamente a 30,30 km<sup>2</sup>.

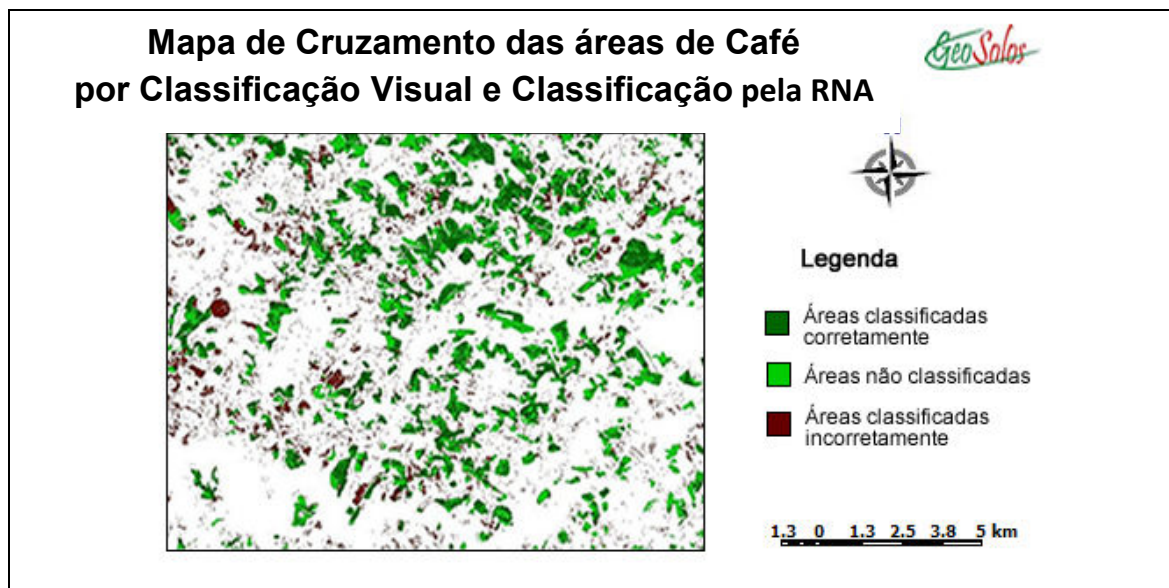


Figura 4. Mapa de cruzamento das áreas de café entre o mapa de referência (classificação visual) e o classificado pela RNA.

## 5. Considerações finais

Neste trabalho imagens de sensoriamento remoto foram classificadas por Redes Neurais Artificiais. Máscaras na rede de drenagem e na área urbana foram incluídas, diminuindo assim a quantidade e a variabilidade dos alvos observados nas imagens. Para validação dos resultados alcançados pela RNA, o mapa resultante desta classificação foi sobreposto a um mapa de referência, obtido por classificação visual. O índice de acurácia Kappa obtido foi de 67,61%, que é um índice considerado bom. Apesar de ainda não ter sido incorporado à RNA, nenhum outro parâmetro, a não ser o espectral, a metodologia proposta possibilitou discriminar todas as classes de saída pré-estabelecidas. O erro na classificação realizada pela rede neural é influenciado pela ambiguidade de áreas de café com áreas de mata, tendo em vista os padrões espectrais muito próximos destas duas classes de uso e cobertura do solo.

Observando o mapa gerado pela RNA, verifica-se a existência de pequenas áreas classificadas incorretamente como café (aparecem como resíduos no mapa), e que na verdade referem-se a outras classes de uso. Quando sobrepostas as linhas de drenagem do IGAM sobre a imagem Landsat, percebe-se que a região estudada possui muitos drenos que não foram digitalizados. Uma sugestão para trabalhos futuros seria fazer a digitalização dos drenos existentes na imagem, e sobre elas refazer a relação de proximidade (*buffer*) e realizar novamente todo o processo de treinamento e classificação pela rede neural.

### Agradecimentos

Os autores agradecem ao apoio da Fundação de Amparo à Pesquisa de Minas Gerais (FAPEMIG), CAPES, CNPq e ao CBP&D/Café pelos recursos financeiros para o desenvolvimento do projeto e bolsas.

### Referências Bibliográficas

- Andrade, L. N.; Vieira, T. G. C.; Lacerda, W. S.; Alves, H. M. R.; Volpato, M. M. L.; Braga, R. C. A.; Souza, V. C. O. **Redes Neurais Artificiais na classificação de áreas cafeeiras da região de Guaxupé**. In: Simpósio de Pesquisa dos Cafés do Brasil, 6., 2009, Vitória. Brasília: Embrapa Café, 2009. CD-ROM.
- Benediktsson, J. A., Swain, P. H., Ersoy, O. K. Neural Network Approaches Versus Statistical Methods in Classification of Multisource Remote Sensing Data. **IEEE Transactions on Geoscience and Remote Sensing**, v. 28, n. 4, p. 540-552, 1990.
- Bernardes, T. **Caracterização do ambiente agrícola do complexo Serra Negra por meio de Sensoriamento Remoto e Sistemas de Informação Geográfica**. 2006 119p Dissertação (Mestrado em Solos e Nutrição de Plantas) – Universidade Federal de Lavras, Lavras, MG.
- Carvalho, L. M. T. **Mapping and monitoring forest remnants: a multiscale analysis of spatio-temporal data**. 2001, 150f. Tese (Doutorado em Sensoriamento Remoto) – Wageningen University, Wageningen, 2001.
- Clark Labs, IDRISI Andes, v.15.00, Clark University, Worcester, 2006.
- Cruz, N. C.; Galo, M. L. B. T. Aplicação de redes neurais artificiais na classificação de imagens multitemporais e multisensor. In: Colóquio Brasileiro de Ciências Geodésicas, 3., 2003, Curitiba. **Anais...** Curitiba: UFPR, 2003. CD-ROM.
- Galparsoro, L. U. Fernández, S. P. **Medidas de concordancia: el índice Kappa**. 2001. Disponível em: <<http://www.fisterra.com/mbe/investiga/kappa/kappa.htm>>. Acesso em: 01 nov. 2008
- Gonzales, R. C.; Woods, R. E. **Processamento de Imagens Digitais**. São Paulo: Edgard Blücher Ltda., 2000. 527 p.
- Hepner, G. F. Artificial Neural Networks Classification using a Minimal Training Set: Comparison to Conventional Supervised Classification. **Photogrammetric Engineering and Remote Sensing**, v. 56, n. 4, p. 469-473, 1990.
- Lippmann, R. P.. An introduction to computing with neural nets. **IEEE ASSP Magazine**, v.4, p. 4-22, 1987.
- Liu, Z. K., Xiao, J. Y. Classification of remotely-sensed image data using artificial neural networks. **International Journal of Remote Sensing**, v. 12, n. 11, p. 2433-2438, 1991.
- Navares J. F.; Vieira, T. G. C.; Lacerda, W. S. **Classificação de áreas cafeeiras por meio de redes neurais artificiais e os aspectos relacionados à reflectância: um estudo exploratório**. In: Simpósio Brasileiro de Sensoriamento Remoto (SBSR), 14., 2009, Natal. São José dos Campos: INPE, 2009.
- TSO, B. AND MATHER, P. M., **Classification Methods for Remotely Sensed Data**. London: Taylor & Francis, 2001.
- Vieira, T. G. C.; Alves, H. M. R.; Lacerda M. P. C.; Veiga R. D.; Epiphany J. C. N. Crop parameters and spectral response of coffee (*Coffea arabica* L.) areas within the state of Minas Gerais, Brazil. **Coffee Science**, v.1, n.2, p.111-118. 2006.
- Vieira, T. G. C.; Lacerda, W. S.; Botelho, T. G. **Mapeamento de áreas cafeeiras utilizando redes neurais artificiais: Estudo de caso na região de Três Pontas, Minas Gerais**. 2009. In: Simpósio Brasileiro de Sensoriamento Remoto. Disponível em: <<http://marte.dpi.inpe.br/col/dpi.inpe.br/sbsr@80/2008/11.13.12.57/doc/7947-7954.pdf>>